

Implementació de bases de dades biomèdiques amb GitHub (II)

Miguel Gallego Cabanillas

9 de febrer de 2026

Resum– Moltes bases de dades biomèdiques depenen de finançament per mantenir-se operatives, fet que dificulta la seva continuïtat i actualització al llarg del temps. En aquest context, un projecte previ va demostrar la viabilitat de migrar una base de dades biomèdica a una arquitectura gratuïta basada en GitHub, eliminant costos d'infraestructura i simplificant el manteniment.

Aquest Treball de Fi de Grau afegeix una capa d'interacció que permet inserir nova informació científica de forma guiada, validada i persistida dins de CollecTF, una base de dades de llocs d'unió de factors de transcripció bacteriana. El procés consisteix en set passos que automatitzen la consulta a APIs públiques, l'estandardització de dades mitjançant ontologies, i l'escriptura segura al repositori de GitHub.

Paraules clau– APIs públiques, aplicació web, arquitectura sense servidor, automatització, bases de dades biomèdiques, bioinformàtica, curació de dades, factors de transcripció, GitHub, GitHub Actions, GitHub Pages, llocs d'unió, ontologies, pipeline de curació, react, SQLite.

Abstract– Many biomedical databases depend on continuous funding to remain operational, which make difficult their long-term sustainability and regular updates. In this context, a previous project demonstrated the viability of migrating a biomedical database to a free architecture based on GitHub, eliminating infrastructure costs and simplifying maintenance.

This Final Degree Project adds an interaction layer that enables the guided, validated and persistent insertion of new scientific information into CollecTF, a database of bacterial transcription factor binding sites. The process is structured into seven steps that automate queries to public APIs, data standardization through ontologies, and secure writing to the GitHub repository.

Keywords– automation, biomedical databases, bioinformatics, binding sites, curation pipeline, data curation, factors of transcription, GitHub, GitHub Actions, GitHub Pages, ontologies, public APIs, React, serverless architecture, SQLite, web application.



1 INTRODUCCIÓ - CONTEXT DEL TREBALL

Avui en dia la bioinformàtica ha d'interpretar una quantitat ingent de dades generades a partir de les noves tecnologies biològiques i experimentals. Malgrat ser un dels sectors pioners en el tractament de big data, una de les problemàtiques més recurrents és la preservació i manteniment

de tot el coneixement recollit. Segons un estudi realitzat per H. J. Imker [1] i, tal com es pot observar a la Figura 1, realitzada per T. K. Attwood [2], aproximadament el 75% de les bases de dades publicades durant els darrers 25 anys han desaparegut o quedat parcialment inaccessibles, ocasionant un fenomen conegut com a “tomba de dades”.

Aquest efecte normalment s'ocasiona quan una base de dades, habitualment desenvolupada per un grup d'investigació reduït i amb finançament temporal, deixa de rebre suport econòmic o institucional. Sense recursos per actualitzar el programari o mantenir la infraestructura, la base de dades es degrada progressivament fins a esdevenir inoperativa. Aquest procés implica la pèrdua d'informació, coneixement científic i inversió feta, i alhora genera la necessitat de tornar a crear recursos que ja existien, dificultant la re-

• E-mail de contacte: gallegocabanillasmiguel@gmail.com
 • Menció realitzada: Tecnologies de la Informació
 • Treball tutoritzat per: Maria Carmen de Toro Valdivia i Ivan Erill Sagales (Àrea de Ciències de la Computació i Intel·ligència Artificial)
 • Curs 2025/26



Fig. 1: Estat de 326 bases de dades bioinformàtiques 18 mesos després de la seva creació.

cerca i reduint-ne l'eficiència.

Fins ara, una base de dades molt utilitzada en l'àmbit de la bioinformàtica ha estat CollecTF [3] [4], on s'emmagatzemen les dades dels bacteris i del lloc exacte del seu ADN en el qual s'uneix una proteïna (factor de transcripció (TF)). Aquesta base de dades ha estat molt utilitzada per la comunitat científica, però actualment està a punt de sofrir el mateix destí que hem esmentat anteriorment, de nou per una manca de finançament.

Cal esmentar que aquest Treball de Fi de Grau serveix de continuació del treball presentat per l'Eloi Milego el juny del 2025 [5], ambdós dirigits pels mateixos directors. En el treball anterior es va buscar una solució, on es va explorar l'ús de repositoris de llarg termini com GitHub [6] per a garantir la supervivència de CollecTF. Es va aconseguir migrar aquesta base de dades al format SQLite [7], que consisteix a encapsular tota la base de dades relacional en un únic fitxer, i desplegar una aplicació web estàtica a GitHub Pages [8] mitjançant GitHub Actions [9] per poder accedir a aquesta base de dades, allotjada dins del repositori GitHub. Aquest primer projecte va demostrar que és possible fer consultes dinàmiques en una base de dades relacional des d'una aplicació *serverless* [10], sense necessitat de finançament permanent i assegurant la lectura i accés públic de la informació. Així doncs, considerant aquest factor, se seguirà la mateixa línia de recerca, amb l'objectiu de garantir una continuïtat fidel i ferma a l'estudi del projecte d'investigació CollecTF de la Universitat de Maryland, dirigit pel doctor Ivan Erill. Aleshores, cal considerar complementaris aquests treballs, ja que s'emmarquen en el mateix projecte.

En aquest segon treball, la principal aportació no és la migració ni l'arquitectura tècnica ja resolta, sinó el fet d'afegir una peça clau que complementa el treball anterior i converteix CollecTF en una base de dades completament operativa i sostenible a llarg termini. Es tracta d'un *pipeline* curatiu, un procés que consisteix en un seguit de passos per sistematitzar la incorporació de les dades sobre els punts d'unió de factors de transcripció de bacteris publicades en publicacions científiques, consultant bases de dades públiques i utilitzant ontologies amb identificadors estandaritzats. L'objectiu d'aquest *pipeline* és, en efecte, inserir la informació de manera guiada, validada i persistent dins la base de dades. Per tant, aquest TFG se centra en la implementació d'aquesta capa d'interacció amb l'usuari, garantint la consistència de les dades, l'ús correcte d'ontologies i identificadors, tot assegurant que la comunitat científica pugui seguir consultant CollecTF sense necessitat d'una infraestructura

costosa, fet que posa fi al risc de la "tomba de dades".

La resta del document s'organitza segons la següent explicació. En primer lloc, es defineixen els objectius generals i específics del projecte. A continuació, es presenta la planificació del treball i la metodologia emprada per al seu desenvolupament. Tot seguit, es descriu l'arquitectura del sistema i el procés de desenvolupament, fent èmfasi en les tecnologies emprades. Posteriorment, s'exposen els resultats obtinguts i s'analitza el funcionament de la solució proposada. En darrera instància, l'informe es tanca amb les conclusions del treball i les possibles línies de treball futur.

2 OBJECTIUS

Amb l'anterior investigació, es va desplegar una infraestructura que permetia obtenir informació de la base de dades, i també, es va constatar que la inserció en aquesta era factible. El present projecte parteix d'aquesta base prèvia i té com a finalitat completar el sistema, desenvolupant la capa d'interacció que permeti inserir nova informació científica de forma guiada, segura i persistent dins la base de dades de CollecTF que ja es troba allotjada a GitHub. Aquest procés s'anomena curació.

Com ja hem esmentat anteriorment, l'objectiu general és el desenvolupament d'un *pipeline* curatiu interactiu que, principalment, ha de permetre inserir dades noves a CollecTF, de forma guiada, validada i persistent, és a dir, que tingui una interfície intuïtiva per a facilitar l'experiència de l'usuari i que sigui accessible a través d'una arquitectura *serverless* desplegada a GitHub.

Per a desenvolupar aquesta tasca, el projecte proposa els següents subobjectius:

1. Implementar una interfície d'usuari orientada a curadors que guiï el procés d'inserció de dades pas a pas de forma intuïtiva.
2. Integrar consultes automàtiques a APIs i bases de dades públiques com PubMed [11], Entrez [12], UniProt [13], CrossRef [14], QuickGO [15], amb l'objectiu de validar informació científica i estandaritzar la classificació de mètodes experimentals, factors de transcripció i llocs d'unió mitjançant ontologies.
3. Desenvolupar els mecanismes tècnics d'escriptura segura a la base de dades SQLite allotjada a GitHub, assegurant la consistència i persistència de les insercions.
4. Integració del *pipeline* curatiu a la infraestructura ja existent.
5. Evitar l'efecte "tomba de dades", establint una proposta replicable per a futurs projectes similars.

3 METODOLOGIA I PLANIFICACIÓ

Per a la realització d'aquest projecte se seguirà una metodologia Scrum [16]. Tot i que no s'assignarà cap rol, sí que es

determinaran diversos *sprints* que tindran una durada aproximada entre dues o tres setmanes. S'ha escollit aquesta metodologia, ja que Scrum facilita un desenvolupament iteratiu, permet adaptar-se a nous requisits i ofereix un control de les funcionalitats de manera progressiva. A més a més, la planificació ha estat definida amb un diagrama de Gantt (apèndix A1), on es recullen tots els *sprints* i les seves subtasques associades de manera estructurada. D'altra banda, per a una bona gestió i l'acompliment amb els terminis establerts, s'ha fet una reunió setmanal, amb l'objectiu de tenir un seguiment continu de la feina feta i establir els propers passos i les millores en cada moment.

Un altre aspecte a destacar per a l'elaboració del treball és la seva corba inicial de dificultat. Les primeres setmanes impliquen l'anàlisi, comprensió del treball previ i familiarització amb l'arquitectura i el codi existent. Probablement, aquest període inicial pot comportar un progrés aparentment més lent, però, a mesura que es consolidi el coneixement i es domini l'estructura del projecte, el ritme de desenvolupament s'agilitzarà. Per tant, s'han definit nou *sprints* a realitzar durant les vint setmanes previstes que ha de durar el projecte, que corresponen a set passos definits pel *pipeline* de curació, més uns *sprints* inicials i un *sprint* final de validació i tancament:

- *Sprint 0* (Setmanes 1-3): Anàlisi del treball previ, preparació, contextualització i planificació del projecte.
- *Sprint 1* (Setmanes 4-5): Anàlisi del *pipeline* original i familiarització amb l'entorn.
- *Sprint 2* (Setmanes 6-7): Comprensió detallada del codi existent i proves inicials.
- *Sprint 3* (Setmanes 8-9): Continuació amb proves bàsiques de codi i disseny del nou *pipeline*.
- *Sprint 4* (Setmanes 10-11): *Step 1* - Publicació.
- *Sprint 5* (Setmanes 12-13): *Step 2* - Informació del genoma i factor de transcripció (TF) i *Step 3* - Mètodes experimentals.
- *Sprint 6* (Setmanes 14-15): *Step 4* - Llocs d'unió reportats
- *Sprint 7* (Setmanes 16-17): *Step 5* - Anotació dels llocs d'unió identificats i *Steps 6 i 7* - Regulació gènica i Informació de la curació.
- *Sprint 8* (Setmanes 18-20): Proves funcionals, validació d'integritat i consistència de les dades, optimització i millores d'UX/UI, migració a l'entorn de producció, fusió amb el treball anterior, tancament de la memòria final, preparació de la presentació i pòster.

Aquesta estructura permet desenvolupar el projecte de forma gradual, on sempre es revisarà que l'*sprint* anterior s'ha realitzat amb èxit abans de començar amb el següent, assegurant que els resultats finals siguin els esperats.

Tal com reflecteix en el diagrama de Gantt, observat a la Figura 6 de la planificació final del projecte, les diferents fases definides s'han pogut realitzar d'acord amb els temps

previstos. Gràcies al seguiment continu de la planificació, s'ha permès completar les tasques sense cap desviació significativa, assolint el projecte dins del calendari definit inicialment.

4 ARQUITECTURA

Abans de definir l'arquitectura i el desenvolupament és important destacar un cop més que el present projecte s'està realitzant a partir d'una arquitectura ja establerta. Aleshores, es farà una petita contextualització del *stack* tecnològic utilitzat fins ara per a entendre el punt de partida i les funcionalitats ja desenvolupades. Més endavant, es definirà amb més detall les noves funcionalitats.




Fig. 2: Arquitectura heretada del projecte anterior. © Eloi Milego

4.1 *Stack* tecnològic de partida

Per començar, el *pipeline* de curació s'integra com un nou procés dins l'aplicació existent reCollecTF¹, mantenint les mateixes decisions de disseny base. D'aquesta manera, el projecte continua essent una Single Page Application (SPA) desplegada a GitHub Pages, utilitzant GitHub Actions per automatitzar el procés de desplegament. La base de dades SQLite segueix allotjada com a fitxer estàtic dins del mateix repositori GitHub, fet que permet una persistència a llarg termini sense necessitat d'infraestructura externa.

D'altra banda, la interfície del *pipeline* s'implementa amb el *framework* de *front-end* React [17], per seguir amb la pista de tecnologies del projecte anterior, seguint un model de desenvolupament basat en Single File Components (SFCs) [18], que permet, amb components independents, modularitzar la implementació de cada pas del procés de curació. SFC és un paradigma utilitzat en molts *frameworks* de *front-end* com Vue [19], Angular [20] o React. D'igual manera, s'utilitzarà TailwindCSS [21] per a seguir amb el mateix disseny i presentació, mantenint coherència visual. A més a més, per gestionar l'estat compartit entre els diferents components del *pipeline*, s'utilitza React Context [22], que gestiona la informació de sessió que cal mantenir entre els diferents passos del procés de curació (per exemple, publicació o informació del genoma/TF).

Mitjançant l'eina Vite [23] integrada en el flux de GitHub Actions, el codi React es compila i es transforma en fitxers HTML + CSS + JavaScript (JS) [24] estàtics per al

¹*reCollectTF* disponible a: <https://erilllab.github.io/reCollectTF/>. Consulta: 05-02-2026.

seu desplegament final. Un cop desplegada l'aplicació, GitHub Pages serveix el fitxer CollecTF.db, el qual conté la base de dades per tal accedir-hi des del navegador. Es continua utilitzant la llibreria `sql.js-httpvfs` de JS, que permet llegir el fitxer SQLite de manera eficient directament des del *front-end*, sense necessitat d'un servidor dedicat. Aquesta estratègia manté l'accés a la base de dades completament *serverless* i alineada amb l'objectiu inicial de garantir la continuïtat del projecte.

L'escriptura a la base de dades CollecTF.db no es pot fer directament des del navegador, ja que per modificar el repositori cal utilitzar un *token* d'accés de GitHub que no es pot exposar al client per qüestions de seguretat. Per aquest motiu, tal com ja es va plantejar al treball d'Eloi Milego, el flux d'inserció es basa, en primer lloc, en l'autenticació dels col·laboradors en GitHub i, en segon lloc, en l'ús de funcions *serverless* de Vercel [25]. Aquest procés es pot observar a la Figura 4.

En la primera fase (*Step 1* de la Figura 4), l'usuari que vol realitzar una inserció s'autentica amb el seu compte de GitHub mitjançant OAuth. Un cop GitHub valida l'autenticació, una funció *serverless* de Vercel rep un codi temporal que s'intercanvia, de manera segura i exclusivament al servidor de Vercel, per un *token* d'accés a l'API de GitHub. Aquest *token* d'accés no s'exposa en cap moment al navegador.

A continuació, Vercel genera un JSON Web *token* (JWT) propi, signat amb una clau privada del servidor Vercel, que encapsula la informació mínima necessària per identificar la sessió de l'usuari. Aquest JWT s'emmagatzema en una *cookie* HTTP-only que és enviada al navegador. D'aquesta manera, el navegador només pot reenviar automàticament la *cookie* a les Vercel Functions en les peticions posteriors, però no pot accedir al seu contingut mitjançant JavaScript. Només els usuaris que han completat aquest procés i estan autoritzats com a col·laboradors del repositori poden accedir als formularis d'inserció i, per tant, fer modificacions sobre el fitxer SQLite.




Fig. 3: Escripció de forma segura a una base de dades estàtica. © Eloi Milego

Quan la persona curadora envia un formulari per afegir dades, l'aplicació transforma les dades introduïdes en instruccions SQL d'inserció i les envia a una Vercel Function. Aquesta funció valida el JSON Web *token* (JWT) emmagatzemat en una *cookie* HTTP-only, comprova que l'usuari està autenticat i extreu, a partir d'aquest JWT, el *token* d'accés a GitHub associat a la sessió (Figures 3 i 4 Step3).

Tot i que aquest *token* d'accés es troba físicament emmagatzemat al navegador, queda encapsulat dins d'una *cookie* HTTP-only i, per tant, no és accessible des de JavaScript ni exposat al client. Només les funcions *serverless* de Vercel poden validar i interpretar el contingut del JWT, fet que garanteix un ús segur del *token* (Figura 3).

Un cop validada la sessió, la Vercel Function utilitza l'API de GitHub Actions per executar el *workflow* `update-db.yml`, una GitHub Action encarregada d'aplicar les insercions sobre el fitxer SQLite del repositori. Posteriorment, el *workflow* `deploy.yml` torna a desplegar l'aplicació amb la base de dades actualitzada (Figura 4). D'aquesta manera, Vercel actua com a interfície segura per implementar el flux OAuth i gestionar l'ús del *token* de GitHub amb l'objectiu de fer insercions a la base de dades, mentre que la lectura continua fent-se directament des de GitHub Pages.




Fig. 4: Sistema d'autenticació i escriptura de l'aplicació web heretada. © Eloi Milego

5 REQUISITS FUNCIONALS

Durant la realització del procés de curació, serà necessari l'ús de la base de dades definida al treball anterior, la qual s'organitza en un conjunt de taules principals que donen suport al *pipeline* de curació. A la Figura 7 de l'apèndix A2 es mostra el diagrama entitat-relació de la base de dades utilitzada en aquest projecte, que serveix com a referència visual del model complet.


Amb aquesta arquitectura de base, i a través del procés de curació que permet transformar la informació extreta de publicacions científiques en dades estructurades i coherents, es podran afegir a CollecTF nous factors de transcripció, les seves famílies, els seus llocs d'unió en el genoma bacterià, i totes les metadades experimentals (publicacions, genomes, ontologies d'evidència, anàlisi de coincidències, funció del factor de transcripció i informació de regulació gènica), de forma estandarditzada i validada. El flux complet està estructurat en set passos i es mostra de manera esquemàtica a la Figura 5. A continuació es definirà amb més detall quina funció té cada pas del procés de curació:

• Step1- Selecció de publicació:

En el primer pas del *pipeline*, l'usuari pot introduir un identificador d'un article científic, sigui el títol, PubMed ID o DOI. El sistema detecta automàticament de quin tipus d'identificador es tracta i consulta les següents APIs públiques per obtenir les dades bibliogràfiques de forma automàtica.

Si es tracta d'un identificador PubMed o del títol, l'aplicació consulta l'API d'Entrez per recuperar les dades principals de l'article (títol, autors, revista, data i DOI). Si l'entrada és un DOI, es realitza primer una cerca per obtenir el PubMed ID associat i, a continuació, s'extreu la mateixa informació seguint el mateix procés.

En cas que l'usuari no disposi de cap identificador de l'arti-

Fig. 5: Diagrama del *pipeline* de curació complet.

cle, té l'opció de consultar la pàgina web oficial de PubMed, on introduint el títol de l'article, es pot obtenir la informació bibliogràfica corresponent. D'aquesta manera, indirectament també està comprovant que les dades obtingudes per part del sistema són correctes, i que pot continuar amb el procés de curació.

Les dades principals recuperades es mostren a l'usuari perquè les revisi i confirmi que siguin correctes. Només en aquest moment es guarda la informació per a posteriorment afegir-la a la base de dades com una nova publicació, mitjançant la creació d'un nou registre a la taula *core_publication*. D'aquesta manera, el sistema automatitza l'obtenció de metadades i evita l'entrada manual d'informació, reduint errors i assegurant consistència en el format de les referències. A la Figura 8 es pot veure un exemple d'aquest pas complet.

• Step2 - Informació del genoma i del factor de transcripció:

En aquest segon pas, l'usuari identifica el factor de transcripció (TF) que s'està estudiant en l'article seleccionat al pas anterior. El sistema consulta la base de dades per oferir suggeriments de coincidència mentre s'escriu el TF, cosa que permet a l'usuari seleccionar-ne un existent o crear-ne un de nou si no es troba cap similitud. En cas d'afegir un nou TF (nou registre a la taula *core_tf*), l'usuari ha d'indicar-ne la família i la descripció, creant un nou registre a la taula *core_tf*, associat a una entrada de *core_tffamily*. Si la família tampoc existeix, el sistema també permet crear-la. Això permet ampliar progressivament el nombre de TF i famílies de manera coherent.

A continuació, l'usuari pot afegir identificadors d'interès biològic (*accession numbers*) procedents de diferents bases de dades públiques: genomes, a través de NCBI [26], proteïnes a través d'UniProt i proteïnes RefSeq a través de NCBI d'igual manera. Quan s'introdueixen *accessions* de proteïnes, aquestes es vinculen al factor de transcripció mitjançant la creació d'una instància a la taula *core_tfinstance*, que representa una proteïna concreta associada a un TF definit. Cada codi introduït es valida automàticament i, si ja existeix a la base de dades, es recupera la informació disponible. En cas contrari, el sistema consulta les APIs externes (Entrez i UniProt) per obtenir-ne l'iden-

tificador i la descripció. Aquesta funcionalitat automatitza l'enriquiment de la base de dades i evita que l'usuari hagi de recopilar informació manualment.

El sistema captura informació contextual sobre l'organisme, on l'usuari pot indicar si els genomes i proteïnes introduïts corresponen exactament al mateix organisme estudiat a l'article, o bé especificar-ne un de diferent si és el cas. Aquest control és important per mantenir la coherència biològica i evitar ambigüitats en etapes posteriors.

Finalment, l'usuari pot marcar si l'article conté informació experimental rellevant, com dades de promotors o expressió gènica. Aquesta informació s'emmagatzema per a ser utilitzada en els *steps* 5 i 6, que depenen d'aquest tipus d'evidència.

En conjunt, aquest pas recull i valida la informació necessària per caracteritzar el factor de transcripció i el seu context biològic, assegurant que els passos posteriors del *pipeline* disposin de dades consistents i verificades. A la Figura 9 es pot veure un exemple d'aquest pas complet i, a la Figura 10 d'aquest mateix pas en cas de voler afegir un nou TF o una nova família de TF.

• Step3 - Selecció de mètodes experimentals:

En aquest pas, l'usuari pot afegir informació sobre els mètodes experimentals que s'han utilitzat a l'article mitjançant codis ECO (Evidence & Conclusion Ontology), que representen identificadors científics estandarditzats. Aquesta informació és clau per documentar com s'ha generat el coneixement sobre el factor de transcripció, fet que resulta essencial per interpretar correctament les dades en etapes posteriors del *pipeline*.

El sistema permet introduir aquests codis ECO manualment o cercar-los mitjançant l'autocompleció a partir de la base de dades de CollecTF. Quan l'usuari selecciona una tècnica existent a la base de dades, aquesta es pot afegir directament a la curació. En cas que no hi sigui, pot desplegar un formulari que permet afegir un nou codi ECO. Es valida que aquest nou codi existeixi a través d'una consulta a l'API de QuickGO. Un cop validat, l'usuari ha de seleccionar la categoria experimental (ja definida en la taula *core_experimentaltechniquecategory*) i una breu descripció. Finalment, si l'usuari confirma les dades introduïdes, el nou

mètode experimental queda incorporat al sistema, ampliant així l'ontologia experimental de manera progressiva. A la Figura 11 es pot veure un exemple d'aquest pas complet i, a la Figura 12 d'aquest mateix pas en cas de voler afegir una nova evidència experimental (codi ECO).

• Step4 - Llocs d'unió reportats:

En aquest quart pas, l'usuari pot introduir seqüències d'ADN (p. ex. AAGATTACATT) que representen els llocs d'unió del TF que apareixen reportats a la publicació. Primerament, el *pipeline* permet seleccionar el tipus de lloc d'unió que s'està incorporant entre les opcions: *motif-associated (new motif)*, *variable motif-associated* i *non-motif-associated*.

Un cop seleccionat el tipus, l'usuari pot introduir múltiples seqüències de llocs d'unió. Quan es confirma l'entrada, el sistema processa les seqüències i inicia una cerca automàtica sobre els genomes introduïts prèviament al *pipeline*. Per fer-ho, des del navegador de l'usuari es descarrega i prepara la informació genòmica associada als *accessions numbers* introduïts al *step 2*, obtenint, d'una banda, la seqüència completa en format FASTA [27] i, de l'altra, les anotacions en format GenBank [28]. Aquesta informació es recupera un cop més mitjançant l'API d'Entrez/NCBI i es manté temporalment en memòria dins l'aplicació web, amb l'objectiu d'evitar descàrregues repetides en el mateix procés de curació.

Amb les seqüències genòmiques disponibles en memòria, el sistema busca coincidències exactes de cada lloc d'unió dins dels genomes, considerant tant el sentit directe com el complementari invers per poder identificar coincidències a ambdues cadenes de l'ADN. Per a cada coincidència exacta detectada, el *pipeline* calcula i mostra la posició d'inici i final del *match*, el genoma on s'ha trobat i l'orientació de la cadena (+ o -), on el signe + indica que el gen es troba a la cadena de l'ADN directa del genoma i - a la cadena complementària inversa. A més a més, utilitzant les anotacions extretes del GenBank, el sistema associa cada *match*, mostrant els gens propers a la zona on cau el lloc d'unió, amb més informació com el *locus tag*², el nom del gen (o identificador alternatiu), la funció (*product*), les coordenades i, de nou, l'orientació. Aquest context facilita que l'usuari validi si el *match* és coherent amb el que es descriu a l'article i que es pugui fer una idea d'on cau el lloc d'unió. A la Figura 13 es pot veure un exemple d'aquest pas complet en cas de fer una selecció d'un *match* exacte.

Si per un lloc d'unió determinat no es troben coincidències exactes o cap de les coincidències presentades és considerada vàlida, l'usuari pot indicar-ho i activar una segona fase de cerca amb tolerància a errors. En aquesta fase, el *pipeline* torna a escanejar el genoma permetent coincidències amb fins a dos *mismatches*, considerant igualment ambdues cadenes. Els resultats, igual que en el cas anterior, es presenten de manera detallada, però ara, quan s'indica la seqüència trobada també s'indica el nombre de discrepàncies i una representació visual simple de les posicions coincidents, amb l'objectiu d'ajudar l'usuari a seleccionar el *match* més probable. A la Figura 14 es pot veure

un exemple d'aquest mateix pas en cas de fer una selecció d'un *match* inexacte.

Abans de poder continuar al pas següent, l'usuari ha d'escollir exactament una coordenada genòmica (sigui una coincidència exacta o amb *mismatches*) per a cada lloc d'unió introduït. Aquesta validació garanteix que tots els llocs d'unió reportats queden correctament associats a coordenades genòmiques, establint una base consistent per a l'anotació funcional i la regulació gènica que es desenvoluparan als *steps 5 i 6*.

• Step5 - Anotació dels llocs d'unió identificats:

En aquest cinquè pas, el *pipeline* permet afegir informació funcional i estructural sobre cada lloc d'unió del TF en el genoma ja seleccionat al pas anterior, així com especificar quines evidències experimentals donen suport a cada lloc concret. L'objectiu és que cada lloc d'unió quedi anotat de manera coherent abans d'entrar a la fase de regulació gènica. Per a cada lloc d'unió, el sistema mostra la seva informació completa, incloent-hi la seqüència genòmica seleccionada en el pas anterior (coordenades, orientació i genoma corresponent). D'aquesta manera, l'usuari pot identificar clarament quin lloc està anotant, tant si prové d'una coincidència exacta com d'una coincidència amb *mismatches*. A continuació, i com a part més important en aquest pas, l'usuari pot definir dos atributs principals associats al factor de transcripció en el context d'aquell lloc d'unió seleccionat al *step 4*:

- **TF-type**, que descriu l'estructura d'unió del TF (p. ex. *monomer, dimer, tetramer, other o not specified*).
- **TF-function**, que indica el rol funcional del TF en la regulació (p. ex. *activator, repressor, dual o not specified*).

Paral·lelament, el pas integra les tècniques experimentals introduïdes i validades al *step 3*, on l'usuari pot marcar, per a cada lloc d'unió, quines tècniques s'han utilitzat específicament per evidenciar-lo. D'aquesta manera, es pot especificar l'evidència experimental associada a cada lloc d'unió de forma individual, més enllà de la llista global de tècniques emprades a la publicació, aportant més precisió a la curació. Per facilitar l'entrada de dades quan es treballa amb una gran quantitat de llocs d'unió, la interfície incorpora funcionalitats d'edició massiva. L'usuari pot seleccionar un subconjunt de llocs d'unió i aplicar-hi de forma conjunta un mateix *TF-type*, una mateixa *TF-function* i, fins i tot, assignar tècniques experimentals a tots els llocs seleccionats. Aquesta funcionalitat redueix la repetició d'accions i ajuda a mantenir consistència quan diverses entrades comparteixen característiques comunes. A la Figura 15 es pot veure un exemple d'aquest pas complet.

• Step 6 - Regulació gènica:

En aquest sisè pas, el *pipeline* permet indicar quins gens estan relacionats amb cada lloc d'unió del factor de transcripció segons la informació descrita a la publicació. L'objectiu d'aquest pas és identificar, a partir del lloc d'unió, quins gens es veuen afectats pel factor de transcripció en l'estudi analitzat.

²Locus tag: Identificador únic assignat a cada gen dins d'un genoma.

Per a cada lloc d'unió seleccionat al *step* 4, el sistema mostra un conjunt de gens propers dins del genoma corresponent. Aquests gens es mostren perquè, en molts casos, els factors de transcripció regulen gens que es troben a poca distància del lloc on s'uneixen a l'ADN. D'aquesta manera, l'usuari disposa del context genòmic necessari per reconèixer quins gens poden estar implicats segons el contingut de l'article.

En cas que al *step* 2 s'hagi indicat que l'article conté informació sobre regulació gènica, l'usuari pot seleccionar, per a cada lloc d'unió, quins d'aquests gens són mencionats a l'article com a regulats pel factor de transcripció. Aquesta selecció serveix per deixar constància explícita de quins gens estan associats a cada lloc d'unió segons l'evidència disponible. En cas contrari, el sistema continua mostrant els gens propers com a informació de referència, però desactiva la selecció i la interacció per evitar introduir informació que no estigui suportada per dades experimentals. A la Figura 16 es pot veure un exemple d'aquest pas complet.

• Step 7 - Informació de la curació:

En aquest darrer pas, el *pipeline* recull la informació necessària per finalitzar la curació de la publicació. L'objectiu és deixar constància de l'estat de la curació i del motiu en cas que no hagi estat possible completar-la amb totes les dades esperades. L'usuari pot indicar si la curació ha estat completada, és a dir, si no hi ha més informació rellevant pendent d'afegir a CollecTF per aquella publicació. Si la curació no ha estat satisfactòria o s'ha hagut d'aturar per alguna limitació, l'usuari pot marcar-la com a revisable en un futur, seleccionant un motiu de revisió dins d'un conjunt d'opcions predefinides (per exemple, absència d'un genoma comparable a NCBI, manca d'una seqüència proteica del TF, o altres motius).

Adicionalment, el sistema disposa d'un camp de notes que permet documentar qualsevol aspecte rellevant del procés de curació, com ara decisions preses durant la selecció dels llocs d'unió, informació que s'ha descartat, o raons concretes per les quals no s'ha pogut completar algun dels passos. Aquestes notes aporten traçabilitat i faciliten que, en una revisió posterior, es pugui entendre el context de la curació realitzada.

Finalment, en confirmar aquest pas, el *pipeline* finalitza el procés i prepara l'escriptura i persistència de la curació a la base de dades, incorporant totes les dades i camps omplerts al llarg dels passos completats. D'aquesta manera, el sistema garanteix que cada publicació quedi registrada amb un estat de curació clar i amb prou informació per reprendre o auditar el procés en el futur. A la Figura 17 es pot veure un exemple d'aquest pas complet.

6 RESULTATS

El desenvolupament del *pipeline* de curació ha permès implementar una versió funcional i completa del procés de validació, anàlisi i escriptura de dades per a CollecTF sense necessitat d'infraestructura pròpia. El sistema integra tots els set passos del *pipeline* de curació, des de la selecció de

la publicació científica fins a la validació final de la curació, incloent-hi la gestió de la informació genòmica, del factor de transcripció, dels llocs d'unió, de les evidències experimentals i dels gens regulats. Un aspecte rellevant dels resultats és que l'ús de l'arquitectura *serverless* i d'una base de dades SQLite allotjada en GitHub no ha limitat la funcionalitat del sistema, tot i haver utilitzat únicament tecnologies gratuïtes.

Un dels resultats més rellevants és que l'ús d'una arquitectura *serverless* conjuntament amb una base de dades SQLite allotjada a GitHub no ha limitat la funcionalitat del sistema. Malgrat utilitzar exclusivament tecnologies gratuïtes i estàndards oberts, el *pipeline* permet realitzar consultes dinàmiques, integrar informació procedent de múltiples APIs externes i garantir l'accés públic i la persistència de les dades curades.

En l'àmbit funcional, el sistema és capaç de treballar amb identificadors de l'ontologia (PMID, DOI, *accession numbers*, ECO codes). En cas que aquests identificadors ja siguin a la base de dades CollecTF no és necessari l'ús de les APIs públiques. En cas contrari, el sistema permet consultar les seves respectives APIs públiques (Entrez, UniProt, QuickGO, respectivament), i retornar informació estructurada perquè l'usuari la validi. A més a més, el *pipeline* gestiona altres casos on els identificadors no existeixen, fet que permet la creació de nous registres amb les dades pertinents. Amb aquest mecanisme es redueixen errors manuals i es fomenta l'ús de les ontologies determinades, fet important en entorns biomèdics.

Des d'una perspectiva de viabilitat, el projecte evidencia que un enginyer informàtic pot abordar aquest tipus de solució amb coneixements de desenvolupament web i gestió de dades, atès que la integració amb APIs facilita el tractament d'informació complexa sense necessitat de coneixement en la part de biologia. Considerant els recursos disponibles, els resultats obtinguts són útils i escalables.

7 CONCLUSIONS

Aquest treball ha tingut com a objectiu principal el desenvolupament d'un *pipeline* de curació interactiu que permetés inserir nova informació científica a la base de dades CollecTF de manera guiada, validada i persistent, mantenint una arquitectura *serverless* desplegada sobre GitHub. Al llarg del projecte s'ha demostrat que aquest objectiu general s'ha assolit satisfactòriament mitjançant la implementació d'un flux de curació estructurat en set passos, integrat amb la infraestructura existent i orientat específicament a les necessitats dels curadors científics.

Pel que fa al primer subobjectiu, la implementació d'una interfície d'usuari orientada a curadors, s'ha materialitzat mitjançant una aplicació web que estructura el procés de curació en passos clarament definits. Aquesta aproximació redueix la complexitat cognitiva del procés, facilita la presa de decisions per part de l'usuari i contribueix a una introducció de dades més consistent i menys propensa a errors.

El segon subobjectiu, la integració de consultes au-

tomàtiques a APIs i bases de dades públiques com PubMed, Entrez, UniProt i QuickGO, s'ha assolit mitjançant un sistema de validació i recuperació automàtica de metadades. Aquesta integració permet contrastar i completar la informació introduïda pels curadors, així com estandarditzar la classificació de mètodes experimentals, factors de transcripció i llocs d'unió mitjançant ontologies reconegudes, millorant la qualitat semàntica i la interoperabilitat de les dades.

En relació amb el tercer subobjectiu, s'han desenvolupat mecanismes d'escriptura segura sobre la base de dades SQ-Lite allotjada a GitHub. L'ús de funcions *serverless* de Vercel combinades amb un flux d'autenticació OAuth amb GitHub permet garantir que només els usuaris autoritzats puguin realitzar insercions, sense exposar credencials sensibles al client web.

El quart subobjectiu, la integració del *pipeline* de curació dins la infraestructura ja existent, s'ha assolit sense necessitat de redissenyar l'arquitectura prèvia. Com hem esmentat al llarg del treball, el sistema desenvolupat reutilitza els mecanismes de desplegament amb GitHub Actions i manté la base de dades com un únic fitxer centralitzat, allotjat a GitHub i servit per GitHub pages, garantint la continuïtat del projecte i facilitant-ne el manteniment futur.

Finalment, el cinquè subobjectiu, evitar l'efecte “tomba de dades”, s'ha abordat mitjançant un disseny modular i progressiu del *pipeline*, així com per la possibilitat d'inserir i actualitzar les dades directament a la base de dades CollecTF allotjada en un repositori GitHub gratuït. L'ús d'estàndards oberts, APIs públiques i tecnologies àmpliament adoptades permet que la solució sigui replicable i extensible a altres projectes de curació científica, contribuint a la sostenibilitat i reutilització de l'enfocament proposat.

En conjunt, els resultats d'aquest treball demostren que el *pipeline* desenvolupat compleix l'objectiu general plantejat i aporta una solució robusta i escalable per a la curació de dades sobre factors de transcripció a CollecTF. Aquesta contribució reforça la qualitat i mantenibilitat de la base de dades, i estableix una base sòlida per a futures ampliacions i projectes similars en l'àmbit de la curació de dades biomèdiques.

8 ÚS DE LA IA GENERATIVA

Per últim, és important destacar quina funció ha tingut la IA generativa durant l'elaboració de tot el projecte. Considerant que la IA és un recurs funcional per a la realització de consultes ràpides, en alguns casos s'ha emprat com a font de consulta. Les dades obtingudes han estat contrastades a posteriori en fonts documentals verificables i acadèmiques. En cap cas, la IA ha esdevingut una font documental principal o primordial, sinó alternativa o complementària a les fonts documentals presentades a la bibliografia final. A més a més, ha actuat com a instrument per a dubtes i consultes específiques, sempre que s'ha tractat d'una qüestió de format, i no pas de contingut.

9 AGRAÏMENTS

Aquest projecte hauria estat impossible sense l'acompanyament i el suport de diverses persones al llarg del seu desenvolupament. En primer lloc, vull expressar el meu agraïment als meus tutors, l'Ivan Erill i la Maria Carmen de Toro, pel seu suport, rigor i implicació constant. Les seves orientacions metodològiques i aportacions tècniques han estat fonamentals per consolidar el plantejament del projecte i garantir-ne la qualitat final.

D'igual manera, m'agradaria reconèixer el suport rebut per part de la meua família i, especialment de la meua parella, que m'han acompanyat de manera contínua durant tot el procés d'elaboració del treball. Tot i no tenir coneixements en bioinformàtica, la seva paciència, comprensió i capacitat d'oferir una visió externa han ajudat de manera significativa a afrontar els reptes del projecte amb una altra perspectiva. Aquest suport personal ha estat clau per mantenir la motivació i la perseverança necessàries fins a la finalització del treball.

REFERÈNCIES

- [1] H. J. Imker, “25 years of molecular biology databases: A study of proliferation, impact, and maintenance,” *Frontiers in Research Metrics and Analytics*, vol. 3, May 2018, online; accessed 13-Sep-2025. [Online]. Available: https://www.researchgate.net/publication/345650858_25_Years_of_Molecular_Biology_Databases_A_Study_of_Proliferation_Impact_and_Maintenance
- [2] T. K. Attwood, B. Agit, and L. B. M. Ellis, “Longevity of biological databases,” *EMBnet.journal*, vol. 21, no. 0, p. 0, 2015.
- [3] S. Kılıç, E. R. White, D. M. Sagitova, J. P. Cornish, and I. Erill, “Collectf: a database of experimentally validated transcription factor-binding sites in bacteria,” *Nucleic Acids Research*, vol. 42, no. Database issue, pp. D156–D160, 2014, online; accessed 13-Sep-2025. [Online]. Available: <https://academic.oup.com/nar/article/42/D1/D156/1051934>
- [4] S. Kılıç *et al.*, “From data repositories to submission portals: rethinking the role of domain-specific databases in collectf,” *Database: The Journal of Biological Databases and Curation*, vol. 2016, p. baw055, 2016, online; accessed 13-Sep-2025. [Online]. Available: <https://academic.oup.com/database/article/doi/10.1093/database/baw055/2630369>
- [5] E. Milego Miralles, M. C. Toro Valdivia, and I. Erill Sagales, “Implementació de bases de dades biomèdiques amb github,” <https://ddd.uab.cat/record/317583>, 2025, bachelor’s Thesis, Universitat Autònoma de Barcelona. Accessed: 13-Sep-2025.
- [6] “Build software better, together,” <https://github.com>, accessed: 20-Sep-2025.
- [7] “Sqlite home page,” <https://www.sqlite.org/index.html>, accessed: 27-Sep-2025.
- [8] “Github pages documentation,” <https://docs.github.com/es/pages>, accessed: 21-Sep-2025.
- [9] “Github actions,” <https://github.com/features/actions>, accessed: 21-Sep-2025.
- [10] P. Utomo and Falahah, “Building serverless website on github pages,” *IOP Conference Series: Materials Science and Engineering*, vol. 879, no. 1, p. 012077, 2020.
- [11] “Pubmed database,” <https://pubmed.ncbi.nlm.nih.gov/37907733/>, accessed: 03-Oct-2025.
- [12] “Entrez api,” <https://www.ncbi.nlm.nih.gov/home/develop/api/>, accessed: 03-Oct-2025.
- [13] “Uniprot database,” https://www.uniprot.org/help/programmatic_access, accessed: 11-Oct-2025.
- [14] “Crossref api,” <https://api.crossref.org/swagger-ui/index.html>, accessed: 14-Nov-2025.
- [15] “Quickgo api,” <https://www.ebi.ac.uk/QuickGO/api/index.html>, accessed: 12-Oct-2025.
- [16] “Scrum - the 2020 scrum guide,” <https://scrumguides.org/scrum-guide.html>, 2020, accessed: 25-Sep-2025.
- [17] “React,” <https://es.react.dev/>, accessed: 27-Sep-2025.
- [18] “Single-file components,” <https://vuejs.org/guide/scaling-up/sfc.html>, accessed: 15-Nov-2025.
- [19] “Vue.js,” <https://vuejs.org/>, accessed: 15-Nov-2025.
- [20] “Angular,” <https://angular.dev/>, accessed: 15-Nov-2025.
- [21] “Tailwind css - rapidly build modern websites without ever leaving your html,” <https://v3.tailwindcss.com/>, accessed: 27-Sep-2025.
- [22] “React context,” <https://react.dev/reference/react/Context>, accessed: 15-Nov-2025.
- [23] “Vite,” <https://vite.dev>, accessed: 27-Sep-2025.
- [24] “Javascript,” <https://developer.mozilla.org/docs/Web/JavaScript>, accessed: 15-Nov-2025.
- [25] “Vercel functions,” <https://vercel.com/docs/functions>, accessed: 21-Oct-2025.
- [26] “Ncbi database,” <https://www.ncbi.nlm.nih.gov/nuccore/>, accessed: 14-Oct-2025.
- [27] “Fasta format,” <https://www.ncbi.nlm.nih.gov/genbank/fastafomat/>, accessed: 29-Nov-2026.
- [28] “Genbank format,” <https://www.ncbi.nlm.nih.gov/genbank/samplerecord/>, accessed: 29-Nov-2026.

APÈNDIX

A1. Planificació


Tal com s'ha esmentat a l'apartat de planificació, s'ha fet ús d'Scrum i un Diagrama de Gantt per a una bona organització i gestió del temps. A la Figura 6 es pot observar aquest diagrama amb tots els *Sprints* i les seves subtasques especificades.

A2. Arquitectura de les dades

A la Figura 7 es mostra el diagrama Entitat-Relació de la base de dades CollecTF utilitzat durant la realització de tot el projecte.

A3. Pipeline de curació

A les següents figures es mostra, pas a pas, tot el *pipeline* de curació desenvolupat en aquest projecte:



CURATION PIPELINE

Step 1: Publication

Step 2: Genome and TF information

Step 3: Experimental Methods

Step 4: Reported Sites

Step 5: Site annotation

Step 6: Gene Regulation

Step 7: Curation information

Summary

Publication
Not selected

Selected TF
Not selected

Genome & TF accessions
None added

Experimental Methods
None added

Additional info
Promoter data: No
Expression data: No

Step 1 – Publication

Search article directly on PubMed

37907733

Search

Simultaneous entry as an adaptation to virulence in a novel satellite-helper system infecting *Streptomyces* species.
Authors: deCarvalho T, Mascolo E, Caruso SM, López-Pérez J, Weston-Hafer K, Shaffer C, Enll I
Journal: The ISME journal
Date: 2023 Dec
PMID: 37907733
DOI: 10.1038/s41396-023-01548-0

Confirm and continue →

Fig. 8: *Step1-* Obtenir l'article a tractar.

CURATION PIPELINE

Step 1: Publication

Step 2: Genome and TF information

Step 3: Experimental Methods

Step 4: Reported Sites

Step 5: Site annotation

Step 6: Gene Regulation

Step 7: Curation information

Summary

Publication
PMID: 37907733
Title: Simultaneous entry as an adaptation to virulence in a novel satellite-helper system infecting *Streptomyces* species.
DOI: 10.1038/s41396-023-01548-0

Selected TF
Name: RelB
Family: RelB

Genome & TF accessions
Genomes:
• NC_000911.1
UniProt:
• Q9P8E2
RefSeq:
• WP_082843895

Experimental Methods
None added

Additional info
Promoter data: No
Expression data: No

Step 2 – Genome & TF

TF Name

RelB

+ Add TF

RelB
ID: 237
Family: RelB
TF Description: RelB is a ribbon-helix-helix (RHH) repressor encoded by the relBE toxin-antitoxin locus of *Escherichia coli* capable of neutralizing the toxicity of RelE and of binding to the relBE operon in a complex with RelE [PMID:19747491].
Family Description: The RelB family of antitoxins is associated with the RelE toxin family. RelB antitoxins bind the RelE toxin and prevent it from inhibiting translation [PMID:19747491].

Genome NCBI accession number

Paste the NCBI GenBank genome accession for the closest species or strain.

Example: NC_000913.2

• NC_000911.1 — *Synechocystis* sp. PCC 6803

This is the exact same strain as reported in the manuscript for the sites.

TF UniProt accession number

Paste the UniProt accession for the TF.

Example: Q87KX2

• Q9P8E2 — transcriptional regulator CmeR [Campylobacter jejuni subsp. jejuni NCTC 11168 = ATCC 700819]

TF NCBI RefSeq accession

Enter RefSeq TF protein accession.

Example: WP_000037239

• WP_002843895 — transcriptional regulator CmeR [Campylobacter jejuni subsp. jejuni NCTC 11168 = ATCC 700819]

This is the exact same strain as reported in the manuscript for the TF.

The manuscript contains promoter information.
Sequence or structure of a TF-regulated promoter.

The manuscript contains expression data.
Evidence for TF-mediated differential gene expression.

Confirm and continue →

Fig. 9: *Step2-* Seleccionar TF, Genoma, identificadors UniProt/RefSeq...

CURATION PIPELINE

Step 1: Publication

Step 2: Genome and TF information

Step 3: Experimental Methods

Step 4: Reported Sites

Step 5: Site annotation

Step 6: Gene Regulation

Step 7: Curation information

Summary

Publication
PMID: 37907733
Title: Simultaneous entry as an adaptation to virulence in a novel satellite-helper system infecting *Streptomyces* species.
DOI: 10.1038/s41396-023-01548-0

Selected TF
Name: LexA
Family: LexA

Genome & TF accessions
Genomes:
• NC_000911.1
UniProt:
• Q9P8E2
RefSeq:
• WP_082843895

Experimental Methods
None added

Additional info
Promoter data: No
Expression data: No

Step 2 – Genome & TF

TF Name

Example: LexA

+ Add TF

Create New TF

TF Name

TFnou

Existing Family

Select a family...

+ Add TF Family

New Family Name

FamiliaNova

Family Description

Això és una prova per afegir una nova família

TF Description

Això és una prova per afegir un nou TF

Save TF Cancel

Fig. 10: *Step2-* Afegir un nou TF i una nova TF family

CURATION PIPELINE

Step 1: Publication

Step 2: Genome and TF information

Step 3: Experimental Methods

Step 4: Reported Sites

Step 5: Site annotation

Step 6: Gene Regulation

Step 7: Curation information

Summary

Publication
PMID: 37907733
Title: Simultaneous entry as an adaptation to virulence in a novel satellite-helper system infecting *Streptomyces* species.
DOI: 10.1038/s41396-023-01548-0

Selected TF
Name: LexA
Family: LexA

Genome & TF accessions
Genomes:
• NC_000911.1
UniProt:
• Q9P8E2
RefSeq:
• WP_082843895

Experimental Methods
• ECO:0005667 — ChIP-Seq
• ECO:0005617 — CAT reporter gene assays

Additional info
Promoter data: No
Expression data: No

Step 3 – Experimental Methods

Enter ECO code or name

Example: ECO:0005667 or ChIP-Seq

+ Add technique

Added techniques:
• ECO:0005667 — ChIP-Seq
• ECO:0005617 — CAT reporter gene assays

Confirm and continue →

Fig. 11: *Step3-* Seleccionar les evidències experimentals (ECO codes)

CURATION PIPELINE

Step 1: Publication

Step 2: Genome and TF information

Step 3: Experimental Methods

Step 4: Reported Sites

Step 5: Site annotation

Step 6: Gene Regulation

Step 7: Curation information

Summary

Publication
PMID: 37907733
Title: Simultaneous entry as an adaptation to virulence in a novel satellite-helper system infecting *Streptomyces* species.
DOI: 10.1038/s41396-023-01548-0

Selected TF
Name: LexA
Family: LexA

Genome & TF accessions
Genomes:
• NC_000911.1
UniProt:
• Q9P8E2
RefSeq:
• WP_082843895

Experimental Methods
• ECO:0005620 — ChIP-PCR
• ECO:0005622 — Comparative genomics search

Additional info
Promoter data: No
Expression data: No

Step 3 – Experimental Methods

Enter ECO code or name

Example: ECO:0005667 or ChIP-Seq

+ Add technique

Create new experimental technique

ECO code

ECO:0007059

Found in QuickGO: confocal laser scanning microscopy evidence (ECO:0007059)

Preset function

Detection of binding

Category

Proteomic assay

Description

Prova d'afegir ECO code

Save new technique

Added techniques:
• ECO:0005620 — ChIP-PCR
• ECO:0005622 — Comparative genomics search

Confirm and continue →

Fig. 12: *Step3-* Afegir una nova evidència experimental

CURATION PIPELINE

Step 1: Publication

Step 2: Genome and TF information

Step 3: Experimental Methods

Step 4: Reported Sites

Step 5: Site annotation

Step 6: Gene Regulation

Step 7: Curation information

Summary

Publication
PMID: 37907733
Title: Simultaneous entry as an adaptation to virulence in a novel satellite-helper system infecting *Streptomyces* species.
DOI: 10.1038/s41396-023-01548-0

Selected TF
Name: LexA
Family: LexA

Genome & TF accessions
Genomes:
• NC_000911.1
UniProt:
• Q9P8E2
RefSeq:
• WP_082843895

Experimental Methods
• ECO:0005620 — ChIP-PCR
• ECO:0005622 — Comparative genomics search
• ECO:0007059 — confocal laser scanning microscopy evidence

Additional info
Promoter data: No
Expression data: No

Step 4 – Reported Sites

Select a site

AAGATTACATT

+ Add site

Exact site matches

Accession	Gene name	Function	start	end	strand
NC_000911.1	relB	RelB toxin-antitoxin locus	3311246	3311251	+
WP_082843895	relB	RelB toxin-antitoxin locus	3311246	3311251	+

Confirm and continue →

Fig. 13: *Step4-* Afegir i seleccionar el lloc reportat del Genoma




Fig. 14: *Step4-* Mostrar *intexact matches*




Fig. 15: *Step5-* Definir el tipus de TF, la seva funció i associar cada evidència experimental amb el lloc d'unió anotat




Fig. 17: *Step7-* Finalitzar el procés de curació




Fig. 16: *Step6-* Seleccionar els gens regulats pel TF